

Rapport de conduite de projet Data & ML

Mise en production d'un modèle de prédiction énergétique

Parc immobilier de la Ville de Seattle

Auteur	Kevin Lebayle
Projet	OC_P13 — Portfolio en situation professionnelle
Parcours	Data Scientist Machine Learning
Application	Space Hugging Face
Code	Dépôt GitHub

Table des matières

Synthèse	2
1 Contexte et analyse des besoins	3
1.1 Présentation du contexte	3
1.2 Collecte et analyse du besoin métier	3
2 Audit de la solution data existante	6
2.1 La solution auditée	6
2.2 Évaluation de l'adéquation aux besoins	6
2.2.1 La fuite de données	6
2.2.2 Une préparation non réutilisable	7
2.2.3 Aucune quantification de l'incertitude	7
2.2.4 Un banc d'essai pour contester les choix d'algorithme	7
2.3 Synthèse des écarts	8
3 Identification d'une solution technique cible	9
3.1 Comparatif d'approches	9
3.2 Architecture cible	10
3.2.1 Une source unique pour la préparation	10
3.2.2 Le serving : une contrainte subie, documentée	11
3.2.3 Un conteneur non déployé aurait été une dette	11
3.3 L'application livrée	11
3.4 Facteurs clés de succès et points de vigilance	12
3.5 Méthodologie de priorisation des cas d'usage	13
4 Appui stratégique et méthodologique	14
4.1 Proposition de démarche projet	14
4.2 Aide à la prise de décision	14
5 Contrôle et suivi du projet	17
5.1 Tableau de bord de pilotage	17
5.2 Outils et process de suivi	17
5.2.1 Empreinte carbone : une mesure qui a tranché	19
5.2.2 Le dispositif volontairement non implémenté	20
6 Conclusion et recommandations	21
6.1 Récapitulatif des décisions	21
6.2 Le plafond de performance	22
6.3 Perspectives d'évolution	22
6.4 Prochaines étapes recommandées	24
6.5 Limites de la démarche	24
7 Annexes	25
7.1 Liens du projet	25
7.2 Journal des écarts avec la solution auditée	25

Synthèse

Ce projet reprend mon propre travail de projet 3, réalisé à un stade où je débutais en machine learning : deux notebooks qui s'arrêtent au score affiché en sortie de cellule. J'y reviens avec deux objectifs distincts :

- **Auditer** le travail exploratoire et le modèle retenu.
- **Industrialiser** : conduire le modèle jusqu'à la mise en production.

Ainsi, ce projet reprend les notebooks d'un projet antérieur de modélisation énergétique (prédiction de la consommation et des émissions du parc immobilier de Seattle) et les porte en production : une application en ligne, un modèle versionné, une chaîne d'intégration continue et un journal de décisions.

Le modèle initial atteignait 0,81 de R^2 sur les émissions en s'appuyant sur des variables calculées depuis la consommation réelle : un utilisateur capable de les renseigner connaît déjà la réponse qu'il vient chercher. Corriger cette "fuite" fait tomber la performance affichée à 0,72, mais rend le modèle utilisable.

En consommation, le modèle initial affichait un R^2 de 0,75. En retirant la fuite, on ne dégrade le modèle que de 0,02 environ.

Chaque estimation est accompagnée d'une fourchette, calibrée par *prédiction conforme* sur des erreurs réellement observées. Sur des bâtiments que le modèle n'a pas vus, la prédiction contient la consommation réelle dans 81 % des cas, pour une cible de 75 %. L'interface annonce explicitement que l'outil sert à classer un parc et à prioriser des audits, pas à chiffrer un bâtiment.

Des bâtiments identiques sur le papier consomment du simple au triple

Parmi 163 immeubles de bureaux de taille comparable, la consommation au pied carré va de 27 à 91 kBtu — un facteur 3,4 que le jeu de données ne permet pas d'expliquer. Une fourchette construite sur cette seule dispersion, au même niveau de confiance, vaudrait un facteur 2,24 : l'ordre de grandeur de celle que produit le modèle. La largeur de l'intervalle est donc fixée par les variables disponibles, pas par le choix de l'algorithme.

Livrables : application publique, dépôt de code, 61 tests automatisés, chaîne CI/CD déployante, registre d'expérimentations, et un journal de seize écarts documentés vis-à-vis de la solution audité.

1 Contexte et analyse des besoins

1.1 Présentation du contexte

L'organisation et son obligation réglementaire

La Ville de Seattle impose depuis 2010, par ordonnance municipale, que tout bâtiment non résidentiel ou résidentiel collectif de plus de 20 000 pieds carrés déclare annuellement sa consommation énergétique. Ce dispositif, le *Building Energy Benchmarking*, sert un objectif public affiché : atteindre la neutralité carbone à l'échelle de la ville. Les données collectées sont publiées en open data, millésime par millésime.

Le service porteur — l'*Office of Sustainability & Environment* — dispose donc d'un inventaire déclaratif annuel de plusieurs milliers de bâtiments, avec leurs caractéristiques structurelles et leurs consommations relevées.

Maturité data et point de départ

La maturité data de l'organisation est asymétrique, et c'est ce déséquilibre qui fonde le besoin.

- **Forces** : une collecte structurée, annuelle, avec un référentiel stable de typologies de bâtiments ; une publication en open data qui rend les données auditables.
- **Faiblesses** : la donnée est *publiée* mais peu *exploitée*. Elle décrit le passé des bâtiments déclarants, et ne dit rien de ceux qui ne déclarent pas — ni de ce qu'il faudrait prioriser.

Le point de départ technique

Un projet antérieur de modélisation a produit deux modèles de régression sous forme de notebooks Jupyter : consommation d'énergie et émissions de gaz à effet de serre, à partir des caractéristiques structurelles. Ces notebooks constituent **la solution existante auditée en section 2**. Ils n'ont jamais été déployés, ni suivis, ni testés.

Périmètre de ce rapport

Ce projet est un projet personnel construit sur des données publiques. Le contexte organisationnel décrit ci-dessus est réel — l'ordonnance, le programme de benchmarking et les données le sont — mais les parties prenantes n'ont pas été interrogées : leurs besoins ont été **reconstitués** à partir de la documentation publique du programme et de la nature même des données publiées. Cette limite est assumée et est rappelée en section 6.5.

1.2 Collecte et analyse du besoin métier

Parties prenantes identifiées

Partie prenante	Attente vis-à-vis de la donnée	Contrainte propre
Service développement durable	Cibler les bâtiments à auditer en priorité, avec des moyens d'audit finis	Budget d'audit contraint, obligation de justifier le ciblage
Propriétaires et gestionnaires	Situer leur bâtiment par rapport à des bâtiments comparables	Ne disposent pas toujours de relevés exploitables
Bureaux d'études énergétiques	Pré-qualifier un parc avant intervention	Ont besoin d'un ordre de grandeur, pas d'une valeur contractuelle
Citoyens et élus	Transparence sur l'empreinte du parc	Données publiques, donc opposables

TABLE 1. Parties prenantes et attentes reconstituées à partir de la documentation du programme.

Hiérarchisation des besoins

Les besoins ont été classés selon deux axes : la valeur pour le service porteur et la faisabilité au regard des données réellement disponibles. Ce croisement élimine d'emblée les besoins que la donnée ne peut pas servir, quelle que soit leur valeur.

Besoin	Valeur	Faisabilité	Décision
Estimer la consommation et l'émission d'un bâtiment non relevé	Élevée	Élevée	Retenu — cœur du projet
Prioriser les audits sur un parc entier	Élevée	Élevée	Retenu
Quantifier la fiabilité de chaque estimation	Élevée	Moyenne	Retenu — différenciant
Expliquer ce qui porte une estimation	Moyenne	Élevée	Retenu
Prédire l'effet d'une rénovation	Élevée	Nulle	Écarté : aucune variable de rénovation dans les données
Suivre la dérive du parc dans le temps	Moyenne	Faible	Écarté : un millésime annuel, un seul utilisateur

TABLE 2. Matrice de priorisation des besoins.

Le besoin qui a réorienté tout le projet

Estimer la consommation d'un bâtiment **non relevé** n'est pas une variante du problème initial : c'est une contrainte qui interdit d'utiliser toute variable dérivée de la consommation. Or la solution existante en utilisait. Ce constat est l'origine de l'écart le plus structurant du projet (section 2.2.1).

Deux cibles sont prédites parce qu'elles répondent à deux décisions distinctes. La consommation d'énergie situe le gisement d'économies ; les émissions servent l'objectif affiché du programme, la neutralité carbone. Les deux ne se déduisent pas l'une de l'autre : à consommation égale, un bâtiment chauffé au gaz ou raccordé au réseau vapeur émet nettement plus qu'un bâtiment tout électrique, l'électricité de Seattle étant très majoritairement hydraulique. Prioriser sur l'énergie ou sur le carbone ne désigne donc pas les mêmes bâtiments.

Contraintes**Métier**

L'outil doit servir la priorisation, pas la facturation. Une estimation à un facteur 2 près est exploitable pour classer, inutilisable pour contractualiser. Cette frontière doit être écrite dans l'interface, pas seulement dans la documentation.

Données

Un seul millésime exploité (2016), 1 655 bâtiments après nettoyage, aucune variable d'usage réel (occupation, horaires, équipements). Le réentraînement est annuel, au rythme de publication.

Opérationnelle

Un seul utilisateur métier, pas d'équipe d'exploitation. Toute brique de supervision ajoutée devra être maintenue par cette même personne — ce qui pèse dans les arbitrages de la section [5.2.2](#).

Réglementaire

Les données sont publiques et les estimations sont opposables. Un chiffre affiché sans sa marge d'erreur serait, dans ce contexte, une information trompeuse.

2 Audit de la solution data existante

2.1 La solution auditée

Outils et technologies

La solution existante est un ensemble de notebooks Jupyter : un notebook d'analyse exploratoire et de préparation, un notebook de modélisation. Bibliothèques : pandas, scikit-learn, seaborn. Aucun script, aucun test, aucune dépendance versionnée, aucun artefact exporté.

Processus d'exploitation

Le pipeline se lit de haut en bas dans les cellules :

2016.csv → nettoyage manuel → dftclean2.csv (déjà transformé) → modélisation → score affiché en sortie de cellule

Le pipeline s'arrête là. Le meilleur modèle n'est ni sérialisé, ni comparé de manière traçable, ni servi. La sortie du projet est un *nombre lu dans une cellule*, et le processus n'est rejouable que par réexécution manuelle du notebook dans l'ordre.

2.2 Évaluation de l'adéquation aux besoins

Critères retenus

Critère	Question posée à la solution existante	Verdict
Pertinence métier	Le modèle peut-il servir un bâtiment non relevé ?	Non
Fiabilité annoncée	La performance affichée mesure-t-elle le cas d'usage ?	Non
Quantification du risque	Une estimation est-elle accompagnée de sa marge ?	Non
Réutilisabilité	La préparation est-elle rejouable à l'inférence ?	Non
Traçabilité	Les choix de modélisation sont-ils auditable ?	Non
Choix d'algorithme	Les modèles retenus tiennent-ils face à l'état de l'art ?	Oui

TABLE 3. Grille d'évaluation de la solution existante.

2.2.1 La fuite de données

Le modèle existant consomme trois variables décrivant la répartition des sources d'énergie du bâtiment — la part de l'électricité, du gaz et de la vapeur dans sa consommation. Ces ratios se calculent en divisant chaque source par la consommation totale.

Le problème n'est pas statistique, il est logique.

Pour renseigner ces ratios, il faut connaître la consommation de chaque source. Il faut donc déjà connaître la consommation totale — c'est-à-dire la réponse que le modèle est censé fournir. **Un utilisateur capable de remplir le formulaire n'a plus besoin du modèle.**

Le remplacement de ces ratios par trois booléens de simple *présence* (« ce bâtiment est-il raccordé au gaz ? ») rend le modèle utilisable. Le coût de cette correction a été mesuré en rejouant les deux protocoles à l'identique.

Modèle	Énergie (R^2)		Émissions (R^2)	
	Avec ratios	Sans ratios	Avec ratios	Sans ratios
GradientBoosting	0,753	0,745	0,808	0,720
CatBoost	0,756	0,744	0,821	0,723

TABLE 4. Coût de la suppression de la fuite, mesuré sur le même jeu de test.

L'asymétrie est frappante et s'explique physiquement. Sur l'énergie, la correction coûte environ **un point** : la consommation totale dépend surtout de la taille et de l'usage, que le modèle conserve. Sur les émissions, elle coûte près de **dix points** : l'électricité de Seattle est largement décarbonée, si bien que les émissions dépendent avant tout du *mix de combustibles* — précisément l'information que les ratios apportaient.

Une performance affichée n'est pas une performance utilisable.

Le R^2 de 0,82 de la solution existante est exact, mais il mesure un problème que personne ne se pose. Le chiffre honnête pour le cas d'usage réel est 0,72. **L'audit fait donc baisser la performance annoncée du projet, et c'est son principal apport.**

2.2.2 Une préparation non réutilisable

La préparation des données de la solution existante est enchevêtrée dans les cellules du notebook : imputations, encodages et calculs de ratios s'appliquent à un DataFrame global, dans un ordre implicite. Rien n'est réutilisable pour traiter un bâtiment isolé.

Trois conséquences pour la mise en production :

1. Un encodeur ajusté sur les données doit être persisté et rechargé, sinon l'inférence encode différemment de l'entraînement.
2. Une variable dérivée d'une année de référence ($\text{Age} = 2016 - \text{YearBuilt}$) dérive mécaniquement chaque année si la référence n'est pas figée.
3. Une modalité inconnue à l'inférence produit silencieusement une colonne parasite plutôt qu'une erreur.

Ces trois points sont des cas classiques de *train/serve skew*. Ils sont traités en section 3.2.1.

2.2.3 Aucune quantification de l'incertitude

La solution existante rend un nombre. Elle ne dit rien de sa fiabilité, alors que l'erreur relative varie fortement d'un bâtiment à l'autre : l'erreur médiane est de 37%, mais un bâtiment sur dix est faux d'un facteur 2 ou plus. Le même nombre affiché recouvre donc des situations radicalement différentes, sans que l'utilisateur puisse les distinguer.

2.2.4 Un banc d'essai pour contester les choix d'algorithme

L'audit ne pouvait pas se contenter de relire les choix de modélisation : il fallait les confronter par la mesure. Six familles ont été rejouées dans le même protocole, dont deux qui n'existaient pas ou n'avaient pas été envisagées.

Modèle	Énergie (R^2)	Émissions (R^2)	Statut
Référence naïve	−0,000	−0,000	Plancher de contrôle
RandomForest	0,725	0,707	Existant
HistGradientBoosting	0,732	0,709	Ajouté
CatBoost	0,744	0,723	Retenu — émissions
GradientBoosting	0,745	0,720	Retenu — énergie
TabPFN	0,764	0,745	Meilleur score, écarté

TABLE 5. Banc d’essai, validation croisée stratifiée à 5 blocs, cible en $\log 1p$.

Le choix d’algorithme de la solution existante est confirmé.

Six familles se tiennent en quatre points de R^2 . Le modèle de fondation TabPFN ne gagne que deux points, dans le bruit d’échantillonnage pour un jeu de test de 331 bâtiments. **La marge n’est pas dans l’algorithme** — un constat qui oriente toute la section « perspectives ».

Les régressions linéaires et le SVR n’ont pas été rejoués : l’audit initial les avait déjà écartés sur mesure, et les reproduire aurait consommé du temps sans apporter d’information nouvelle. Cet arbitrage est documenté plutôt que silencieux.

2.3 Synthèse des écarts

Seize écarts par rapport à la solution existante ont été consignés au fil du projet, chacun avec son étape, son changement et son impact attendu. Le journal complet figure en annexe 7.2. Les cinq structurants :

Réf.	Écart	Impact
E08	Ratios d’énergie → booléens de présence	Le modèle devient utilisable sans relevé. −10 points sur les émissions
E01	Correction d’un copier-coller sur deux bâtiments	Deux observations fausses en moins
E07	19 modalités de quartier ramenées à 13 réelles	29 bâtiments sortis de catégories fantômes
E11	Encodage binaire → one-hot	Supprime des relations numériques arbitraires et un objet à persister
E16	Saisie des usages alignée sur l’entraînement	Supprime un <i>train/serve skew</i> sur 9% des bâtiments

TABLE 6. Écarts structurants. Journal complet en annexe 7.2.

Le journal contient également une seconde table : les constats relevés mais **volontairement non corrigés**.

3 Identification d'une solution technique cible

3.1 Comparatif d'approches

Famille d'algorithmes

Approche	Avantages / inconvénients	Décision
Ensembles d'arbres	+ état de l'art sur données tabulaires de cette taille ; robustes aux échelles, aux valeurs extrêmes et aux variables catégorielles encodées. – n'extrapolent pas hors du domaine vu.	Retenu. Un modèle par cible
Modèle de fondation tabulaire (TabPFN)	+ meilleur score du banc d'essai (+2 points). – licence interdisant la production ; artefact lourd ; 101 fois plus d'énergie à l'entraînement pour un gain dans le bruit.	Écarté , sur deux motifs indépendants
Réseaux de neurones	+ aucun apport attendu sur 1 655 lignes et 32 variables. – coût de mise au point sans contrepartie.	Écarté sans test
Régression linéaire, SVR	– déjà écartés sur mesure par l'audit initial.	Non rejoués

TABLE 7. Comparatif des familles d'algorithmes.

Comment exprimer l'incertitude

Le besoin « quantifier la fiabilité de chaque estimation » admettait trois réponses techniques.

Approche	Analyse	Décision
Intervalle paramétrique	Suppose des résidus gaussiens homoscedastiques. Sur une cible étalée sur cinq ordres de grandeur et un modèle à arbres, l'hypothèse ne tient pas.	Écarté
Prédiction conforme par validation croisée	Garantie de couverture <i>sans hypothèse</i> sur la loi des erreurs ; les scores de conformité sont calculés hors bloc, donc aucune donnée n'est sacrifiée.	Retenu
Régression quantile conformalisée	Produit des fourchettes de largeur <i>variable</i> selon le bâtiment — plus proche d'une garantie individuelle. Testée : écart de couverture conditionnelle de 4,5 points, dans le bruit binomial pour des sous-groupes de $n \approx 66$.	Écarté après mesure

TABLE 8. Comparatif des approches d'estimation de l'incertitude.

Le niveau de confiance est un réglage, pas un résultat

La largeur de la fourchette se choisit avant de la calculer. Elle s'élargit vite avec le niveau visé, ce qui en fait un arbitrage produit et non un paramètre technique.

Niveau visé	Fourchette énergie	Fourchette émissions	Couverture observée
70 %	÷1,9 à ×1,9	÷2,1 à ×2,1	77,0 % / 74,3 %
75 %	÷2,0 à ×2,0	÷2,3 à ×2,3	81,3 % / 81,0 %
80 %	÷2,2 à ×2,2	÷2,6 à ×2,6	84,6 % / 84,3 %
90 %	÷3,0 à ×3,0	÷3,6 à ×3,6	91,2 % / 91,5 %
95 %	÷4,0 à ×4,0	÷4,6 à ×4,6	95,5 % / 94,0 %

TABLE 9. Arbitrage largeur / fiabilité. Le niveau retenu est **75 %**.

Justification du niveau retenu

À 95 %, la fourchette va du quart au quadruple de l'estimation : plus fiable, mais elle ne permet plus d'arbitrer quoi que ce soit. 75 % est le point où elle reste exploitable pour décider. Le réglage est par ailleurs *tenu et dépassé* : on demande 75 %, on observe 81 % sur des bâtiments jamais vus.

3.2 Architecture cible




FIGURE 1. Architecture cible. Une seule brique traverse les deux mondes : `src/features.py`.

3.2.1 Une source unique pour la préparation

Le module `src/features.py` est la réponse aux trois défauts de réutilisabilité relevés en section 2. Trois règles le gouvernent :

Aucun état appris n'est persisté.

Les vocabulaires — 13 quartiers, 64 types d'usage repliés en 11 groupes — sont des constantes versionnées avec le code. Il n'y a donc pas d'encodeur à sauvegarder, ni à recharger, ni à désynchroniser.

Un seul chemin d'assemblage.

Les deux points d'entrée, celui du lot et celui du formulaire, convergent vers la même fonction. Un test vérifie qu'un bâtiment saisi et la même ligne passée par le lot produisent des vecteurs *identiques*, variable par variable.

Une modalité inconnue lève une exception.

En production, un bâtiment mal encodé est pire qu’une prédiction refusée : il produit un chiffre plausible et faux.

3.2.2 Le serving : une contrainte subie, documentée

L’architecture initialement retenue — un conteneur Docker servant une interface Streamlit — est devenue inapplicable en cours de projet, pour des raisons commerciales externes.

1. Le 30 avril 2025, l’hébergeur a déprécié le SDK Streamlit (« *Streamlit applications are now created using the Docker template* »).
2. En juillet 2026, la création de *Spaces* Gradio et Docker est passée derrière un abonnement payant, avec une seule exception : un compte personnel gratuit peut héberger jusqu’à deux Spaces Gradio sur l’infrastructure ZeroGPU.

La bascule vers Gradio n’est donc pas un choix esthétique : c’est le seul chemin gratuit restant.

Point de vigilance associé : ZeroGPU refuse de démarrer une application ne déclarant *aucune* fonction GPU, même purement CPU. Une fonction marqueur, jamais appelée, satisfait ce contrôle sans consommer de quota, et un test la protège, car une fonction jamais appelée ressemble à du code mort.

3.2.3 Un conteneur non déployé aurait été une dette

La conteneurisation étant devenue payante, la question s’est posée d’écrire tout de même un Dockerfile. Elle a été tranchée par la négative : non déployé, il constituerait une **seconde définition du runtime** en parallèle du fichier de dépendances, vouée à diverger sans que rien ne le signale. La compétence est attestée par des projets antérieurs ; la dette, elle, aurait été nouvelle.

3.3 L’application livrée

L’interface est organisée autour des trois cas d’usage hiérarchisés plus haut. Deux principes de présentation la gouvernent : le résultat domine visuellement, et il n’apparaît jamais sans sa fourchette.

FIGURE 2. Saisie d’un bâtiment. Les parts d’usage sont contrôlées en direct : l’interface collecte des pourcentages qui doivent totaliser 100 %, et un champ distinct porte le nombre total d’usages déclarés (écart E16).




FIGURE 3. Résultat. La fourchette est donnée au même niveau que l’estimation, et les contributions sont traduites en *facteurs multiplicatifs* : le modèle travaillant sur le logarithme de la cible, une contribution additive devient un multiplicateur, forme directement lisible par un non-spécialiste.



FIGURE 4. Portefeuille : le parc ressort trié par émissions estimées décroissantes, c’est-à-dire dans l’ordre où lancer les audits.

3.4 Facteurs clés de succès et points de vigilance

Facteur clé de succès	Pourquoi
Préparation partagée	Élimine par construction l’écart entraînement / inférence
Fourchette systématique	Sans elle, l’estimation serait lue comme une mesure
Artefacts versionnés avec le code	2,1 Mo : un téléchargement au démarrage n’ajouterait qu’un mode de panne
Versions épinglées sur celles de l’entraînement	Un modèle désérialisé par une autre version se dégrade sans erreur
Point de vigilance	Mesure de maîtrise
Dépendance à un hébergeur gratuit	Les conditions ont déjà changé deux fois ; le code reste portable
Domaine d’entraînement restreint	Un avertissement s’affiche hors du domaine, sans bloquer
Garantie de couverture marginale	Écrit dans l’onglet « modèle & limites » plutôt que passé sous silence
Réentraînement annuel	Chaîne de tests exécutable avant tout redéploiement

TABLE 10. Facteurs de succès et vigilances.



FIGURE 5. Synthèse de portefeuille. La barre de concentration est l’apport principal de l’onglet : elle montre combien de bâtiments portent la moitié des émissions du parc, ce qui transforme une liste en plan d’audit.

3.5 Méthodologie de priorisation des cas d’usage

Trois cas d’usage ont été identifiés à partir des besoins de la section 1.2, puis hiérarchisés selon la valeur métier et le coût de mise en œuvre. Ils ont tous les trois été livrés, dans cet ordre.

Rang	Cas d’usage	Justification du rang	Livrable
1	Priorisation d’un parc	Sert directement le besoin le plus valorisé ; un CSV suffit en entrée	Onglet portefeuille
2	Estimation d’un bâtiment	Porte d’entrée pédagogique de l’outil et démonstrateur de la fourchette	Onglet bâtiment
3	Explication d’une estimation	Nécessaire à l’acceptation, mais sans valeur seul	Facteurs multiplicatifs

TABLE 11. Hiérarchisation des cas d’usage.

4 Appui stratégique et méthodologique

4.1 Proposition de démarche projet

Méthodologie retenue

La démarche suit **CRISP-DM**, avec une adaptation : la phase de déploiement n'est pas un aboutissement mais une contrainte amont. Le besoin « servir un bâtiment non relevé » a été posé *avant* la modélisation, et c'est lui qui a disqualifié les variables en fuite. Une démarche où le déploiement arrive en dernier aurait laissé la fuite passer jusqu'en production.

Le cycle est itératif dans les faits : la découverte de la fuite en phase de préparation a provoqué un retour en compréhension du métier, et la contrainte d'hébergement rencontrée en phase de déploiement a provoqué un retour en conception.

Feuille de route

Phase	Objet	Livrable de sortie	Jalon
0	Cadrage	Plan de travail, dépôt initialisé, règle de traçabilité	Périmètre arrêté
1	Reprise et audit des données	Jeu nettoyé, journal d'écarts ouvert	Données rejouables
2	Préparation partagée	src/features.py, analyse bivariée	Préparation figée
3	Modélisation et arbitrages	Banc d'essai, conformalisation, artefacts	Modèles exportés
4	Application	Interface, trois cas d'usage	Application locale
5	Industrialisation	Tests, CI/CD, déploiement	Application en ligne
6	Restitution	Rapport, portfolio	Soutenance

TABLE 12. Feuille de route par phases.

Responsabilités

Le projet est conduit par une personne seule, ce qui n'annule pas la question des rôles mais la déplace : chaque rôle doit être *explicitement endossé* à un moment donné, faute de quoi il est oublié.

Rôle endossé	Ce qu'il a effectivement produit
Analyste métier	Reconstitution des besoins, matrice de priorisation, périmètre
Auditeur	Grille d'évaluation de l'existant, mise en évidence de la fuite
Data scientist	Préparation, banc d'essai, conformalisation
Ingénieur MLOps	Tests, CI/CD, versionnement des artefacts, déploiement
Concepteur d'interface	Hierarchie visuelle, formulation métier de l'incertitude

TABLE 13. Rôles endossés au cours du projet.

4.2 Aide à la prise de décision

Risques et opportunités

Risque	Gravité	Réponse apportée
Estimation prise pour une mesure	Élevée	Fourchette systématique, usage écrit dans l'interface
Dérive de versions entre entraînement et service	Élevée	Versions épinglées et vérifiées par un test dédié
Changement des conditions de l'hébergeur	Moyenne	Déjà survenu deux fois ; le code reste portable
Bâtiment hors domaine soumis à l'outil	Moyenne	Avertissement non bloquant au-delà du domaine observé
Réentraînement dégradant le modèle	Moyenne	Seuils de non-régression bloquants en intégration continue
Abandon de maintenance	Faible	Aucune brique à surveiller en continu, par conception
Opportunité	Condition de réalisation	
API réutilisable par un tiers	Acquise, générée par le cadre applicatif	
Extension à d'autres millésimes	Le pipeline est rejouable ; coût marginal faible	
Extension à d'autres villes	Non : romprait l'hypothèse d'échangeabilité	

TABLE 14. Synthèse des risques et opportunités.

Scénarios budgétaires

Les coûts d'infrastructure sont documentés ci-dessous. Le coût de mise en œuvre est exprimé en jours-homme ; sa valorisation dépend du taux journalier retenu et n'est donc pas chiffrée ici.

Scénario	Coût récurrent	Ce qu'il apporte	Décision
Hébergement gratuit	0 \$	Application publique, mise en veille automatique après inactivité	Retenu
Abonnement PRO	9 \$ / mois	Débloque le conteneur Docker et le matériel CPU dédié	Écarté : n'achète qu'une différence d'outillage
Matériel CPU dédié	≈ 22 \$ / mois	Supprime le temps de démarrage à froid	Écarté : voir ci-dessous

TABLE 15. Scénarios budgétaires d'infrastructure.

Indicateurs de succès

Indicateur	Cible	Nature
Erreur relative médiane hors bloc	$\leq 40\%$	Technique, bloquant en CI
Couverture observée des fourchettes	$\geq 75\%$	Technique, bloquant en CI
Bornes ordonnées sur tout le parc	100 %	Technique, bloquant en CI
Suite de tests au vert avant déploiement	100 %	Technique, bloquant
Part des émissions couverte par les 20 % premiers audits	À mesurer	Métier
Taux de confirmation d'une priorisation par l'audit réel	À mesurer	Métier
Nombre de bâtiments pré-qualifiés sans déplacement	À mesurer	Métier

TABLE 16. Indicateurs de succès techniques et métier.

Les indicateurs métier sont marqués « à mesurer » et non renseignés : ils supposent un retour d'usage qui n'existe pas encore. Les afficher avec des valeurs inventées les rendrait inutiles.

Impacts pris en compte**Éthique et réputationnel**

Les données sont publiques et nominatives à l'échelle du bâtiment. Publier qu'un bâtiment identifié est « le plus consommateur de sa catégorie » sur la foi d'une estimation fautive d'un facteur 2 serait dommageable pour son propriétaire. C'est la raison première pour laquelle la fourchette est affichée au même niveau que l'estimation, et non en note de bas de page.

Légal

Les estimations sont opposables dans un contexte réglementaire. L'interface indique explicitement qu'elles ne peuvent servir ni à facturer, ni à contractualiser, ni à dimensionner un investissement.

Données personnelles

Aucune donnée à caractère personnel n'est traitée : le jeu décrit des bâtiments, pas des occupants. Le RGPD n'est pas applicable au traitement.

Environnemental

L'empreinte de l'entraînement a été mesurée plutôt qu'estimée, et cette mesure a servi un arbitrage réel (section 5.2.1).

Organisationnel

La solution n'ajoute aucune brique à surveiller en continu, ce qui est une décision de conception assumée pour un service disposant d'un seul utilisateur métier et d'aucune équipe d'exploitation.

5 Contrôle et suivi du projet

5.1 Tableau de bord de pilotage

Indicateurs suivis

Dimension	Indicateur	Valeur au terme du projet	Fréquence
Délais	Phases achevées	6 sur 6	Par phase
Coûts	Coût d'infrastructure récurrent	0 \$	Mensuelle
Livrables	Application, dépôt, tests, rapport	Livrés	Par phase
Qualité des données	Lignes retenues après nettoyage	1 655 sur 1 656	Par millésime
	Écarts documentés vis-à-vis de l'existant	16	Au fil de l'eau
	Modalités inconnues acceptées silencieusement	0 (exception levée)	Continu
Performance ML	R^2 hors bloc, énergie	0,745	Par réentraînement
	R^2 hors bloc, émissions	0,723	Par réentraînement
	Erreur relative médiane	36,6 % / 45,1 %	Par réentraînement
	Couverture observée des fourchettes	81,3 % / 81,0 %	Par réentraînement
Qualité logicielle	Tests automatisés	61, tous au vert	À chaque <i>commit</i>
	Analyse statique	Sans avertissement	À chaque <i>commit</i>
Empreinte	Énergie du banc d'essai complet	7,3 Wh	Par campagne

TABLE 17. Tableau de bord de pilotage.

Mode de reporting

Trois canaux, chacun avec sa fréquence propre :

À chaque *commit*

La chaîne d'intégration continue exécute l'analyse statique puis les tests. Un échec bloque le déploiement — le reporting est ici un verrou, pas une information.

À chaque campagne de modélisation

Le registre d'expérimentations enregistre paramètres, métriques et empreinte. Aucune comparaison de modèles ne repose sur un chiffre recopié à la main.

Au fil de l'eau

Le journal d'écarts reçoit une ligne *au moment* du changement, jamais après coup. C'est ce qui rend la section 2 de ce rapport rédigeable sans reconstitution a posteriori.

5.2 Outils et process de suivi

Suivi des expérimentations

26 exécutions ont été enregistrées : douze modèles évalués sous deux protocoles — avec et sans les variables en fuite — plus les deux modèles de production. Chaque exécution porte ses paramètres, ses métriques, sa durée et son empreinte carbone.

Les deux modèles retenus sont inscrits au registre de modèles avec un alias @champion, ce qui rend la sélection auditable : on peut répondre à la question « pourquoi ce modèle-ci ? » par une trace, pas par un souvenir.

Ce que le suivi a réellement servi

Sans registre, la comparaison « avec ratios / sans ratios » aurait été une impression. Avec, elle est un tableau : la fuite coûte 9,7 points sur les émissions et 1,3 point sur l'énergie. C'est ce chiffre qui a permis d'*assumer* la baisse de performance auprès d'un lecteur qui n'y aurait vu qu'une régression.

Run Name	Created	Duration	Models	Metrics	Parameters
ratios_P3-emissions-TabPFN	2 days ago	35.4s	-	MedAE_unite: 15.30791587... MedAPE: 0.318210815... R2_log: 0.839679364... F1: 0.577967589... RMSE_log: 0.083939656... co2_g: 0.001497879... kwh: 35.43649673...	emissions, ratios_P3, TabPFN
ratios_P3-emissions-CatBoost	2 days ago	3.7s	-	MedAE_unite: 16.87610366... MedAPE: 0.329527613... R2_log: 0.820567557... F1: 0.611850537... RMSE_log: 0.080772912... co2_g: 0.000156550... kwh: 3.702047586...	emissions, ratios_P3, CatBoost
ratios_P3-emissions-HistGradientBoosting	2 days ago	0.6s	-	MedAE_unite: 16.82330048... MedAPE: 0.379096607... R2_log: 0.818545414... F1: 0.615288553... RMSE_log: 0.0001213461... co2_g: 0.000021653... kwh: 0.550616979...	emissions, ratios_P3, HistGradient...
ratios_P3-emissions-GradientBoosting	2 days ago	0.6s	-	MedAE_unite: 18.00608089... MedAPE: 0.382820105... R2_log: 0.807864057... F1: 0.633139150... RMSE_log: 0.000977305... co2_g: 0.000017439... kwh: 0.566379547...	emissions, ratios_P3, GradientBoo...
ratios_P3-emissions-RandomForest	2 days ago	1.3s	-	MedAE_unite: 17.98607187... MedAPE: 0.380368013... R2_log: 0.793216235... F1: 0.656830151... RMSE_log: 0.002978947... co2_g: 0.000023158... kwh: 1.258762121...	emissions, ratios_P3, RandomFore...
ratios_P3-energie-TabPFN	2 days ago	36.0s	-	MedAE_unite: 85667.9999... MedAPE: 0.314913352... R2_log: 0.779149679... F1: 0.615283712... RMSE_log: 0.085322860... co2_g: 0.001522562... kwh: 35.98243522...	energie, ratios_P3, TabPFN
booleans-energie-TabPFN	2 days ago	38.1s	-	MedAE_unite: 863272.7499... MedAPE: 0.326366528... R2_log: 0.764250275... F1: 0.635699688... RMSE_log: 0.088862181... co2_g: 0.001585720... kwh: 38.05319428...	energie, booleans, TabPFN
ratios_P3-energie-CatBoost	2 days ago	3.7s	-	MedAE_unite: 914391.3395... MedAPE: 0.3317569914... R2_log: 0.756156165... F1: 0.648520486... RMSE_log: 0.008726173... co2_g: 0.000155716... kwh: 3.688881874...	energie, ratios_P3, CatBoost
ratios_P3-energie-GradientBoosting	2 days ago	0.7s	-	MedAE_unite: 950076.0288... MedAPE: 0.366226454... R2_log: 0.753265645... F1: 0.650341118... RMSE_log: 0.001221352... co2_g: 0.000021794... kwh: 0.583407163...	energie, ratios_P3, GradientBoo...
ratios_P3-energie-HistGradientBoosting	2 days ago	0.6s	-	MedAE_unite: 959873.7487... MedAPE: 0.364163175... R2_log: 0.748485129... F1: 0.656611123... RMSE_log: 0.001342516... co2_g: 0.000023956... kwh: 0.566929340...	energie, ratios_P3, HistGradient...
booleans-energie-GradientBoosting	2 days ago	0.5s	-	MedAE_unite: 922818.1350... MedAPE: 0.3685656724... R2_log: 0.744664112... F1: 0.661554034... RMSE_log: 0.000878834... co2_g: 0.000015682... kwh: 0.483376979...	energie, booleans, GradientBoo...
booleans-emissions-TabPFN	2 days ago	36.1s	-	MedAE_unite: 20.96313323... MedAPE: 0.424608204... R2_log: 0.744548513... F1: 0.730044072... RMSE_log: 0.084976567... co2_g: 0.001516382... kwh: 36.12319254...	emissions, booleans, TabPFN
booleans-energie-CatBoost	2 days ago	3.7s	-	MedAE_unite: 933442.7377... MedAPE: 0.361878552... R2_log: 0.743520856... F1: 0.663059389... RMSE_log: 0.008729971... co2_g: 0.000155783... kwh: 3.708766460...	energie, booleans, CatBoost
ratios_P3-energie-RandomForest	2 days ago	1.2s	-	MedAE_unite: 939479.3543... MedAPE: 0.355381501... R2_log: 0.737249482... F1: 0.671116925... RMSE_log: 0.000050656... co2_g: 0.000038725... kwh: 1.226918458...	energie, ratios_P3, RandomFore...
booleans-energie-HistGradientBoosting	2 days ago	1.9s	-	MedAE_unite: 949742.2220... MedAPE: 0.373761384... R2_log: 0.732230863... F1: 0.677495884... RMSE_log: 0.003184640... co2_g: 0.000056829... kwh: 1.833375215...	energie, booleans, HistGradient...
booleans-energie-RandomForest	2 days ago	1.4s	-	MedAE_unite: 928011.5880... MedAPE: 0.362722238... R2_log: 0.725122953... F1: 0.688425280... RMSE_log: 0.003258716... co2_g: 0.000058150... kwh: 1.376919507...	energie, booleans, RandomFore...

FIGURE 6. Registre d'expérimentations. Chaque exécution porte ses métriques, sa durée et son empreinte, ce qui rend la comparaison « avec ratios / sans ratios » vérifiable plutôt qu'affirmée.

Intégration et déploiement continu

Étape	Rôle
Analyse statique	Style et erreurs détectables sans exécution
Suite de tests	61 tests : préparation, invariants du modèle, interface, configuration de déploiement
Déploiement conditionnel	Uniquement sur la branche principale, uniquement si tout est vert

TABLE 18. Chaîne d'intégration et de déploiement.

Un choix mérite d'être signalé : la chaîne installe les dépendances **depuis le fichier de dépendances de l'application**, et non depuis l'environnement de développement. La suite valide donc les artefacts contre la pile exacte que le service fera tourner, et non contre celle du poste du développeur.

Trois défauts réels attrapés par le dispositif

Le dispositif de contrôle n'est pas décoratif : il a produit trois constats que la relecture humaine n'avait pas produits.

1. **Une borne négative en production.** Un bâtiment sur 1 655 sortait avec une borne basse d'émissions à $-0,134 \text{ tCO}_2\text{e}$. La cause est structurelle : la cible étant transformée en logarithme, la soustraction du




FIGURE 7. Un cycle complet : les tests conditionnent le déploiement, qui ne s’exécute que sur la branche principale.

quantile de conformité passe sous zéro pour une valeur minuscule. Corrigé par une projection sur le domaine physiquement admissible, sans perte de couverture.

- 2. **Une dérive d’environnement.** L’exécution des tests depuis un environnement Python différent a révélé une bibliothèque d’apprentissage en version 1.8 alors que les artefacts avaient été produits en 1.9. Servi ainsi, le modèle aurait été désérialisé par une version autre que celle qui l’a ajusté — sans erreur ni avertissement. C’est le mode de panne silencieux que le test de configuration a été écrit pour attraper.
- 3. **Une contrainte de plateforme non documentée.** Le déploiement a échoué sur une limite de longueur d’un champ de métadonnées, refusée non pas au niveau du champ mais de *tout l’envoi*, après que les tests soient passés au vert. Un test vérifie désormais cette contrainte en amont.

5.2.1 Empreinte carbone : une mesure qui a tranché

L’empreinte de chaque entraînement a été mesurée modèle par modèle. Le résultat utile n’est pas le total, il est dans les rapports.

Modèle	Durée	Énergie	R^2 énergie
GradientBoosting	0,48 s	0,016 Wh	0,745
RandomForest	1,38 s	0,058 Wh	0,725
CatBoost	3,71 s	0,156 Wh	0,744
TabPFN	38,05 s	1,586 Wh	0,764

TABLE 19. Consommation par modèle, cible énergie.

Le seul arbitrage que la mesure a réellement tranché

TabPFN consomme à lui seul **84 %** de l’énergie du banc d’essai complet, soit **101 fois** le modèle retenu, pour un gain de deux points dans le bruit d’échantillonnage. Il était déjà écarté pour sa licence ; la mesure lui donne un **second motif de rejet, indépendant du premier**.

Trois limites de l’indicateur sont documentées plutôt que passées sous silence :

- **En absolu, la mesure n’arbitre rien.** Le banc d’essai complet a consommé 7,3 Wh et émis 0,41 g de CO₂e — l’équivalent d’une ampoule LED allumée trois quarts d’heure.



FIGURE 8. La suite de tests. Les quatre fichiers couvrent la préparation des données, les invariants du modèle, les points d'entrée de l'interface et la configuration de déploiement.

- **Sous deux secondes, elle n'est pas reproductible.** Entre deux campagnes, les modèles les plus rapides varient de +39 % et -58 %, quand les plus longs tiennent à quelques pourcents près.
- **Le lieu pèse plus que le modèle.** Le facteur de conversion mesuré est de 56 g CO₂/kWh (mix français) ; sur un mix nord-américain le même calcul émettrait cinq à sept fois plus. Un chiffre d'empreinte n'est comparable qu'à un autre produit sur la même infrastructure.

5.2.2 Le dispositif volontairement non implémenté

Aucune supervision de dérive n'a été mise en place, et c'est une décision, pas un oubli. Les données sont publiées une fois par an, le modèle est réentraîné au même rythme, et le service compte un seul utilisateur métier sans équipe d'exploitation. Une brique de supervision aurait ajouté un service à héberger, à authentifier et à maintenir, pour détecter une dérive dont la fréquence d'apparition est celle du réentraînement lui-même.

Ce que coûte une bonne pratique appliquée sans discernement

Le coût de maintenance aurait dépassé le bénéfice attendu. L'arbitrage est documenté ici précisément parce qu'un lecteur pourrait y voir une lacune : c'est l'absence de justification, et non l'absence de l'outil, qui constituerait le défaut.




FIGURE 9. Coût énergétique de chaque point de performance. L'échelle des abscisses est logarithmique : les cinq premiers modèles tiennent dans une décade, TabPFN seul en occupe deux de plus.

6 Conclusion et recommandations

6.1 Récapitulatif des décisions

Décision	Fondement	Nature
Supprimer les variables en fuite	Un utilisateur capable de les renseigner n'a pas besoin du modèle	Structurante
Accompagner toute estimation d'une fourchette	Un nombre seul est lu comme une mesure	Structurante
Fixer le niveau de confiance à 75 %	Au-delà, la fourchette cesse d'être exploitable	Arbitrage produit
Écarter TabPFN	Licence <i>et</i> 101 fois l'énergie pour un gain dans le bruit	Sur mesure
Écarter la régression quantile conformalisée	Gain de couverture conditionnelle dans le bruit	Sur mesure
Écarter ParkingRatio	Confirme un arbitrage de la solution audité	Sur mesure
Basculer vers Gradio	Seul chemin gratuit après changement des conditions de l'hébergeur	Contrainte subie
Ne pas écrire de Dockerfile	Non déployé, il aurait constitué une dette	Arbitrage assumé
Ne pas superviser la dérive	Coût de maintenance > bénéfice à cette échelle	Arbitrage assumé
Versionner les artefacts avec le code	2,1 Mo : un téléchargement n'ajouterait qu'un mode de panne	Technique

TABLE 20. Décisions prises et leur fondement.

6.2 Le plafond de performance

Le résultat le plus solide du projet est une limite, et il détermine à lui seul où se trouvent les marges de progression.

La mesure

On regroupe les bâtiments que le modèle voit comme *interchangeables* — même groupe d'usage dominant, même tranche de surface — et on observe la dispersion réelle de leur intensité énergétique. Cet écart est irréductible : aucun modèle utilisant ces variables ne peut le prédire.

Groupe comparable	<i>n</i>	<i>p</i> ₁₀	<i>p</i> ₉₀	Rapport
Bureaux, grande tranche	163	27,2	90,9	3,35
Bureaux, tranche moyenne	120	31,4	105,3	3,35
Entrepôts secs	69	9,8	71,0	7,27
Salles et assemblées	70	14,6	99,7	6,83
Enseignement	62	24,9	61,5	2,47

TABLE 21. Dispersion de l'intensité (kBtu/pi²) entre bâtiments indiscernables.

Le modèle est au plafond

Une fourchette construite sur cette seule dispersion irréductible, au même niveau de confiance, vaudrait un facteur **2,24**. Le modèle produit un facteur **2,03**. Il est donc *plus serré* que l'écart naturel entre bâtiments que les données ne permettent pas de distinguer.

L'explication physique

Les variables disponibles décrivent **ce qu'un bâtiment est**, alors que sa consommation dépend de **comment il est utilisé et exploité** :

- le taux d'occupation et les horaires — un plateau à 30 % d'occupation contre un autre plein, ouvert 40 h ou 90 h par semaine : un facteur 2 à lui seul ;
- les équipements installés — salle serveurs, cuisine professionnelle, imagerie médicale : invisibles dans les données, décisifs dans la facture ;
- l'âge et le rendement des systèmes de chauffage et de climatisation ;
- la qualité de l'enveloppe — deux immeubles de 1960 dont l'un a été rénové sont indiscernables dans ce jeu de données ;
- les consignes de température et la régulation.

6.3 Perspectives d'évolution

La marge n'est pas dans l'algorithme

Six familles de modèles se tiennent en quatre points de R^2 , et le modèle de fondation ne gagne que deux points. Investir dans un meilleur algorithme reviendrait à optimiser la seule dimension qui ne bouge plus.

Les gains sont dans les **données**, par ordre décroissant d'effet attendu :




FIGURE 10. En haut, l'étendue réelle des intensités au sein de groupes que le modèle ne peut pas distinguer. En bas, la conséquence : la dispersion imposerait à elle seule une fourchette d'un facteur 2,24, alors que le modèle en produit une de 2,03.

1. données d'occupation — effectifs, horaires d'ouverture ;
2. inventaire des équipements énergivores ;
3. âge et type des systèmes de chauffage et de climatisation ;
4. indicateurs d'enveloppe — année de rénovation, performance thermique ;
5. sous-comptage par usage.

Deux extensions à moindre coût, indépendantes des données ci-dessus : exploiter plusieurs millésimes plutôt qu'un seul, ce que le pipeline permet déjà ; et mesurer l'empreinte de l'inférence, qui n'a pas été instrumentée alors que c'est elle qui tourne en continu.

6.4 Prochaines étapes recommandées

Rang	Étape	Effort
1	Confronter la priorisation à des audits réels — c’est le seul moyen de renseigner les indicateurs métier laissés vides	Externe au projet
2	Rejouer le pipeline sur plusieurs millésimes et mesurer la stabilité des estimations dans le temps	Faible
3	Instrumenter l’empreinte de l’inférence et la rapporter au nombre de bâtiments traités	Faible
4	Négocier l’accès à une source d’occupation, même partielle, sur un sous-ensemble du parc	Élevé, hors périmètre technique

TABLE 22. Étapes recommandées, par ordre de valeur.

6.5 Limites de la démarche

Trois limites doivent accompagner la lecture de ce rapport.

Les besoins sont reconstitués.

Aucune partie prenante n’a été interrogée. Les besoins ont été déduits de la documentation publique du programme et de la nature des données. Une collecte réelle aurait pu faire émerger des besoins que ce rapport ignore.

La garantie de couverture est marginale.

Elle vaut en moyenne sur un parc, pas bâtiment par bâtiment, et ne se transporte pas automatiquement à chaque typologie. C’est la limite principale de la méthode retenue, et elle est écrite dans l’interface.

Le rendu visuel de l’application n’a pas été vérifié automatiquement.

Les tests couvrent le comportement, pas l’apparence ; la vérification visuelle est restée manuelle.

7 Annexes

7.1 Liens du projet

Livrable	Adresse
Application en ligne	https://huggingface.co/spaces/KLEB38/OC_P13_seattle_energy_emission_predictions
Code source	https://github.com/KL38/OC_P13_ML_MLOPS_Building_Energy_model
Données source	Seattle Building Energy Benchmarking, millésime 2016, open data municipal

7.2 Journal des écarts avec la solution auditée

Chaque ligne a été écrite *au moment* du changement, jamais reconstituée après coup. C'est cette discipline qui rend la section 2 vérifiable.

Réf.	Étape	Changement	Impact attendu
E01	Nettoyage	Deux bâtiments reçoivent leurs propres valeurs d'usage au lieu de celles d'un troisième (copier-coller)	Deux observations fausses en moins
E02	Imputation	Nombre d'étages : 16 valeurs nulles imputées par la médiane calculée (2) au lieu d'une constante codée en dur (4)	Imputation adaptée à une distribution très asymétrique ; se recalcule si les données changent
E03	Nettoyage	Suppression d'une instruction morte (imputation de valeurs manquantes inexistantes)	Aucun sur les valeurs. Lisibilité
E04	Périmètre	Le notebook s'arrête au nettoyage et exporte des données <i>non transformées</i>	Permet de rejouer la même préparation à l'entraînement et à l'inférence
E05	Imputation	Nombre de bâtiments : règle conservée, mais justifiée par vérification factuelle plutôt que par proximité à la moyenne	Aucun changement de valeur ; hypothèse défendable en soutenance
E06	Environnement	pandas épingle en 2.3.3, non par préférence mais parce que le registre d'expérimentations borne cette dépendance	Aucun sur les valeurs : les notebooks rejoués donnent des résultats identiques
E07	Nettoyage	Quartiers : 19 modalités brutes ramenées à 13 quartiers réels (casse et suffixes)	29 bâtiments sortis de six catégories fantômes de 1 à 9 individus ; 6 colonnes de moins
E08	Fuite de données	Ratios de sources d'énergie remplacés par trois booléens de présence	Écart structurant. –10 points sur les émissions, mais le modèle devient utilisable sur un bâtiment non relevé
E09	Variable	Âge supprimé, année de construction conservée brute	Aucun sur les métriques (transformation affine). Supprime une dérive annuelle mécanique
E10	Composition	Parts d'usage normalisées sur la somme des surfaces déclarées, et non sur la surface totale	La couverture réelle allait de 0 à 6,43 ; la composition devient robuste et correspond à ce que l'interface collecte

suite page suivante

Réf.	Étape	Changement	Impact attendu
E11	Encodage	Quartiers en one-hot (13 colonnes) au lieu d'un encodage binaire (5 colonnes)	Supprime des relations numériques arbitraires entre quartiers et un objet à persister
E12	Variables écartées	Type principal non retenu ; surface totale réduite à son logarithme ; surface bâtie écartée	Évite 21 colonnes redondantes dont plusieurs à moins de 15 exemples
E13	Variable testée	Ratio de parking réintroduit pour contester un arbitrage antérieur, puis retiré après mesure	Aucun écart net au final. Un arbitrage de la solution auditée confirmé sur preuve
E14	Périmètre	Un bâtiment retiré : aucune répartition d'usage déclarée	1 655 lignes au lieu de 1 656. Point hors domaine qui aurait faussé l'évaluation
E15	Robustesse	Un usage ou un quartier inconnu lève une exception au lieu de produire une colonne fantôme	En production, un bâtiment mal encodé est pire qu'une prédiction refusée
E16	Inférence	L'interface collecte les trois usages principaux <i>et</i> le nombre total d'usages déclarés	Supprime un écart entraînement / inférence sur les 9 % de bâtiments à plus de trois usages

Écarts assumés, non corrigés

Relevés pendant le portage, laissés en l'état après décision. Un écart assumé et documenté vaut mieux qu'un écart oublié.

Étape	Constat	Décision
Analyse univariée	Une échelle logarithmique écarte silencieusement les valeurs nulles de trois graphiques : la distribution affichée n'est pas celle des données	Conservé — cosmétique, sans effet sur les données exportées
Composition d'usages	Pour les 9 % de bâtiments déclarant plus de trois usages, la composition est calculée sur une répartition tronquée puis renormalisée	Conservé — la source ne publie pas mieux, et l'interface applique désormais la même troncature (E16)